Université Gustave Eiffel

# M2 MCC

# Projet

# 2024-2025

# Prédire l'origine neurale des signaux magnétiques

## 1. Modalités du projet

- Le module ne pourra pas être validé sans la soutenance du projet.
- Les projets peuvent être réalisés soit individuellement, soit par binôme. Dans le cas de binôme, les deux étudiants doivent travailler en commun ou se répartir le travail de façon équitable. Dans tous les cas, chaque étudiant doit avoir une vue complète et se sentir responsable de l'ensemble du projet sur lequel il travaille. Attention au contrôle effectué en fin de projet, la note de projet sera donnée individuellement (à chaque étudiant et non à chaque binôme).
- Une attention particulière sera apportée aux explications et à la clarté du rendu
- Enfin, laissez libre cours à votre imagination pour enrichir votre modèle.

## 2. Introduction

L'activité cérébrale produit des courants électriques qui génèrent des champs électromagnétiques. Les signaux électriques et magnétiques résultant de l'activité cérébrale peuvent être enregistrés sur le cuir chevelu des sujets à l'aide de l'électroencéphalographie (EEG) et de la magnétoencéphalographie (MEG) respectivement.

Dans ce projet, nous nous concentrerons sur les signaux magnétiques enregistrés par MEG. L'objectif est d'estimer un modèle capable de prédire quelles zones du cerveau sont à l'origine du signal MEG mesuré.

### 2.1. Origine des signaux électrique du cerveau

La communication entre les cellules du cerveau (neurones) s'effectue au niveau des synapses. C'est là que le signal est transmis d'un neurone à l'autre, provoquant la circulation d'un courant électrique à l'intérieur et à l'extérieur du neurone. Un courant entrant dans une partie du neurone (formant un puit de courant) circule à l'intérieur du neurone et doit le quitter à un autre endroit (formant une source de courant). La paire sources et puits de courant forme un

dipôle. Le dipôle généré par un seul neurone peut donc être considéré comme un vecteur dont la direction et la longueur changent constamment (cf Figure 1).

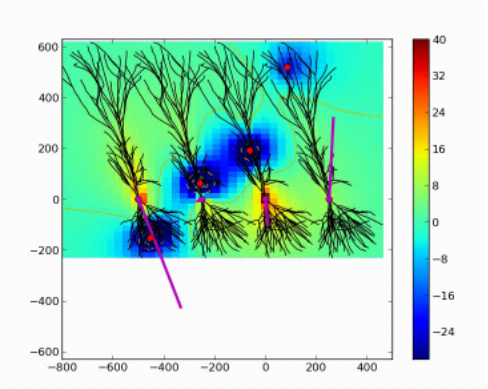


*Figure 1 : Exemple de dipôle du cerveau*

## 2.2. Origine des signaux magnétique du cerveau

Si l'on considère les courants électriques et les dipôles décrits au chapitre 2.1, on peut imaginer des champs magnétiques formant des boucles fermées autour d'eux (cf Figure 2).

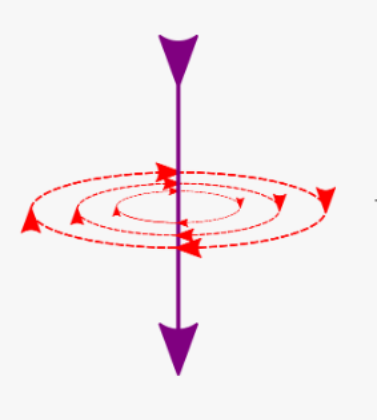

*Figure 2 : Champ magnétique (en rouge, le courant étant en violet)*

Les neurones sont constamment actifs, recevant et propageant des signaux électriques, mais un seul neurone est relativement petit et le potentiel qu'il génère est donc trop faible pour être enregistré sur le cuir chevelu. Cependant, le cerveau humain compte des milliards de neurones qui, ensemble, forment les structures cérébrales. De nombreux types de neurones sont alignés et corrélés. Comme vous pouvez l'imaginer, dans cet environnement, certains des dipôles unicellulaires sont annulés tandis que les autres s'additionnent pour former un signal beaucoup plus fort. Ce signal de groupe (provenant des dipôles unicellulaires qui s'additionnent) ainsi que beaucoup de bruit peuvent être enregistrés par MEG ou EEG.

## 2.3. MEG en pratique

Il se passe beaucoup de choses dans le cerveau humain à chaque instant, alors comment savoir quels signaux rechercher ? Le sujet participant à une expérience de neurosciences cognitives est généralement invité à effectuer plusieurs fois la même tâche (regarder quelque chose sur un écran, se souvenir de quelque chose, appuyer sur des boutons, etc.) Les signaux enregistrés

au cours de toutes les répétitions de l'expérience sont ensuite moyennés, ce qui permet de réduire le bruit et d'obtenir des données plus claires concernant cette tâche. C'est ce que l'on appelle les réponses évoquées. Cependant, l'un des principaux défis auxquels sont confrontés les neuroscientifiques consiste à déterminer l'origine exacte du signal. La résolution de ce problème est connue sous le nom "d'imagerie de la source MEG", de "localisation de la source" ou de "cartographie électromagnétique du cerveau".

### 2.4. Fondements mathématiques de l'imagerie de source MEG

Si l'on désigne par $x \in \mathbb{R}^p$ les données MEG à un moment donné, où $p$ est le nombre de capteurs, on constate que $x$ est obtenu à partir d'une combinaison linéaire de sources. La linéarité vient de la linéarité des équations de Maxwell. En supposant que les sources peuvent provenir d'un ensemble fini de $q$ emplacements dans le cerveau, les données $x$ sont liées aux amplitudes des sources $z \in \mathbb{R}^q$ par l'intermédiaire d'une matrice $L$ de taille $p \times q$, connue sous le nom de "matrice du champ de plomb", de "gain" ou "d'opérateur direct". Elle représente la sensibilité de chaque capteur aux signaux provenant de chaque emplacement de source. Par exemple, si la valeur de $L_{i,j}$ est élevée, cela signifie qu'un signal de la $j ème$ source d'amplitude $z_j$ entraînerait une mesure élevée dans le capteur $i ème$, c'est-à-dire un fort coefficient $x_i$. Inversement, si la valeur de $L_{i,j}$ est proche de 0, cela signifie qu'un signal provenant de la $j ème$ source se traduirait par une mesure très faible dans $i ème$ le capteur.

En supposant la présence d'un bruit additif $n \in \mathbb{R}^p$, cela conduit à :

$$x = Lz + n.$$

Il s'agit d'un modèle de régression linéaire, et $z$ correspond aux coefficients de régression.

Dans ce projet, nous allons résoudre le problème de l'imagerie de la source, c'est-à-dire estimer $z$ à partir de $x$ : grâce aux données MEG simulées, vous devez prédire la ou les régions cérébrales (sources) d'où proviennent ces signaux.

## 3. Exploration des données

Les données sont dans le répertoire data. Ce répertoire contient un répertoire pour les données d'entrainement et un répertoire pour les données de tests

Les données comportent un grand nombre de colonnes nommées e1, e2, ... e204 colonnes nommées 'subject' et 'L_path'. Chaque colonne marquée d'un 'e' correspond à l'enregistrement d'un des capteurs MEG. Nous avons utilisé 204 capteurs pour les enregistrements MEG. Chaque ligne représente le signal de l'ensemble des 204 capteurs à un moment donné pour une simulation. Rappelons que chaque simulation consiste en des signaux générés à partir d'une ou plusieurs sources, qui sont sélectionnées de manière aléatoire.
*subject* est l'identifiant du participant sur lequel l'enregistrement a été effectué. *L_path* est un chemin vers des données supplémentaires pour chaque sujet dont nous ne nous occuperons pas.

Le nombre de sujets est beaucoup plus petit que le nombre de lignes car il y a un grand nombre de simulations pour chaque sujet.

Vous disposez d'un ensemble de données assez important avec 10 000 échantillons par sujet pour entraîner vos modèles et 500 échantillons par sujet pour les tester avec 5 sujets différents pour les données d'entraînement et 5 sujets différents les données de test.

Définissons à présent ce que nous entendons par "source". Le cerveau est une masse continue et nous pourrions donc considérer des millions de points (neurones individuels) comme une source potentielle. Classiquement, pour l'imagerie des sources MEG/EEG, le cortex est discrétisé. Ceci est illustré dans la Figure 3 où chaque point jaune est l'emplacement potentiel d'une source. Vous voyez ici environ 4 000 emplacements échantillonnés dans l'hémisphère gauche. Avec deux hémisphères, on obtient environ 8 000 emplacements, ce qui signifie que l'on suppose que $q \approx 8000$. Rappelons que nous avons $z \in \mathbb{R}^q$

*Figure 3 : discrétisation du cortex*

L'objectif est de retrouver $z \in \mathbb{R}^q$ à partir de $x \in \mathbb{R}^p$ avec $q$ beaucoup plus grand que $p$. Le problème est "mal posé". Pour simplifier la tâche dans le cadre de ce projet, nous avons subdivisé le cerveau de chaque sujet en 450 sous-régions ; leur nom technique est "parcelle" (225 parcelles par hémisphère, le corps calleux, situé entre les deux hémisphères, étant exclu). Chaque parcelle fait partie d'une région plus vaste qui a une signification anatomique représentée par des couleurs différentes sur la Figure 4.

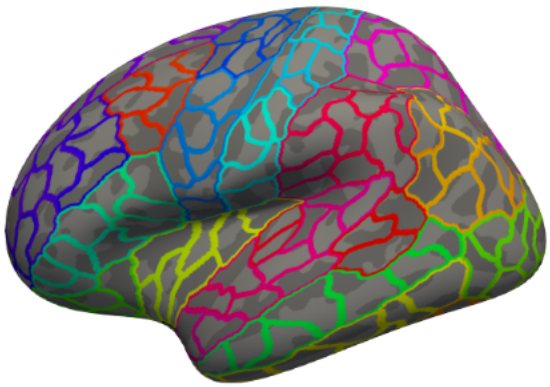

*Figure 4 : subdivision du cerveau en parcelles*

Votre tâche consiste à prédire de quelle(s) parcelle(s) provient le signal MEG. Vous aurez donc un tableau principalement rempli de 0. Chaque colonne représente l'une des 450 parcelles du cerveau. Un 1 indique que la source du signal provient de cette parcelle du cerveau. Chaque ligne des données représente un échantillon. Ce problème peut être considéré comme un problème de classification binaire à sorties multiples (prédire quelle parcelle est active ou non) ou également comme un problème de classification à étiquettes multiples puisque votre tâche se résume à la prédiction d'une liste de parcelles actives. On se limitera à 3 sources au maximum.

## 4. Travail à réaliser

Votre tâche consiste à prédire de quelle(s) parcelle(s) provient le signal MEG. Pour cela on utilisera deux méthodes : les *k plus proches voisins* et les *réseaux de neurones*.

Dans un premier temps, vous devrez :

- Lire, comprendre et visualiser les données.
    - De quelle taille est la matrice d'entrainement ?
    - Combien y a-t-il de sujets ?
    - Afficher la cible
        - De quelle taille est la cible ?
        - Combien y a-t-il de source dans les 3 premiers exemples ?

Une fois les données bien comprises, on peut commencer à mettre en place des algorithmes d'IA.

Concernant la méthode des *k plus proches voisins*, vous utiliserez les librairies de scikit learn, en particulier KNeighborsClassifier

- Comprendre le fonctionnement de cette méthode (*k plus proches voisins*).

- Pour mettre en place le modèle, vous utiliserez les librairies de scikit learn, en particulier KNeighborsClassifier. Faites apparaitre les différents hyperparamètres choisis et n'hésitez pas à les faire varier pour étudier leur influence.
- Utiliser ensuite un classifieur linéaire de type *Lasso*. On utilisera les librairies linear-model et LassLars de scikit learn
- Vous mettrez ensuite en place un réseau de neurones
- Faites apparaitre clairement les résultats des différents algorithmes et l'influence des hyperparamètres.

Enfin, laissez libre cours à votre imagination et testez différentes méthodes et différents hyperparamètres !